Analisi Empirica della Dinamica di Apprendimento: Double Descent, Neural Collapse e CKA

Marco Bardazzi

Università degli Studi di Firenze
Computer Vision and Intelligent Media Recognition

4 marzo 2026

Agenda della Presentazione

1. Introduzione Teorica
2. Setup Sperimentale
3. Analisi dei Risultati (Exp 1, 2, 3)
4. Analisi delle Rappresentazioni (CKA)
5. Conclusioni

Il Paradigma Moderno: Deep Double Descent

La Teoria Classica:

- Trade-off Bias-Varianza a forma di "U".
- Modelli complessi memorizzano il rumore ("overfitting").

La Realtà del Deep Learning:

- Superata la **soglia di interpolazione**, l'errore di test torna a scendere.
- Modelli massivamente sovra-parametrizzati generalizzano in modo eccellente.

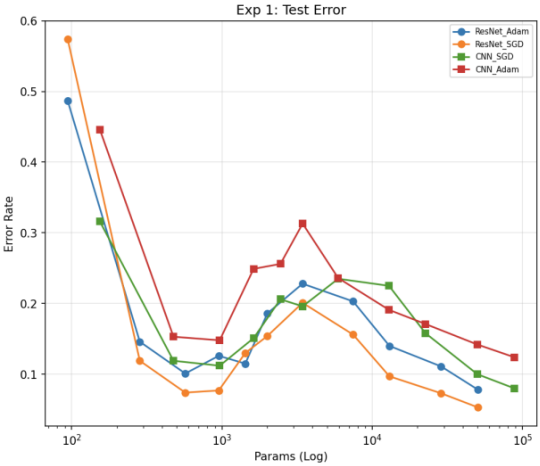

Cos'è il Neural Collapse (NC)?

Nelle fasi terminali dell'addestramento, le rappresentazioni dell'ultimo strato mostrano 4 proprietà geometriche (Papyan et al., 2020):

1. **NC1 (Variability Collapse):** Le attivazioni convergono verso il loro centro di classe (varianza intra-classe $\to 0$).
2. **NC2 (Simplex ETF):** I centri delle classi si dispongono simmetricamente, massimizzando la distanza (Equiangular Tight Frame).
3. **NC3 (Self-Duality):** I pesi del classificatore lineare si allineano perfettamente ai centri di classe.
4. **NC4 (NCC):** Le previsioni della rete coincidono con una classificazione Nearest Class Center.

Setup Sperimentale

Obiettivo: Unire empiricamente Double Descent, Neural Collapse e analisi delle similarità tra strati (CKA).

- **Dataset:** MNIST-1D. Dati a bassa dimensionalità ma morfologicamente complessi.
- **Rumore introdotto:** **20% Label Noise**. Forza la rete a memorizzare etichette errate, esacerbando il picco di interpolazione.
- **Architetture:** `ResNet1D` e `StandardCNN1D`.
- **Scaling:** Larghezza variabile da $W = 2$ a $W = 64$ ($10^2 \to 10^5$ param).
- **Ottimizzatori:** SGD vs Adam.

Risultati: La Rottura del Collapse nel Regime Critico

- L'errore di generalizzazione correla perfettamente con la metrica **NC1**.
- Attorno ai $10^3 - 10^4$ parametri, la varianza intra-classe esplode. Il modello rompe la sua geometria per memorizzare il rumore.
- Superata la soglia ($> 10^4$), il Neural Collapse si ripristina e l'errore crolla.

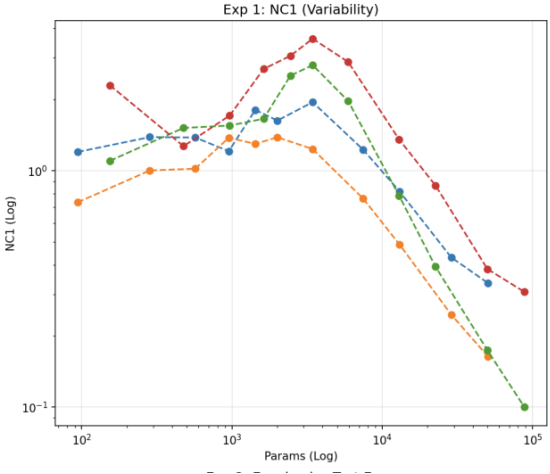

L'Impatto dell'Ottimizzatore: SGD domina Adam

- Nel regime "overparameterized", **SGD** raggiunge configurazioni geometriche (NC2) molto migliori.
- **Adam** tende a bloccarsi in minimi locali sub-ottimali dal punto di vista geometrico.
- **Perché?** SGD possiede un *bias induttivo implicito* che penalizza la norma dei pesi e favorisce margini ampi e simmetrici.

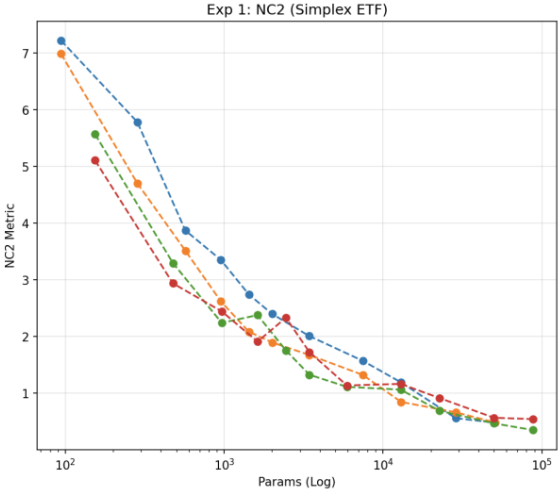

Le Dinamiche di Addestramento (Epoch-wise)

Confronto tra due configurazioni:

- **Critical ($W = 12$):** Posto sul picco del Double Descent. La superficie di perdita è frammentata, portando a enormi oscillazioni dell'errore.
- **Large ($W = 64$):** La capacità in eccesso permette un apprendimento rapido delle feature robuste, relegando la memorizzazione del rumore senza distruggere la generalizzazione.

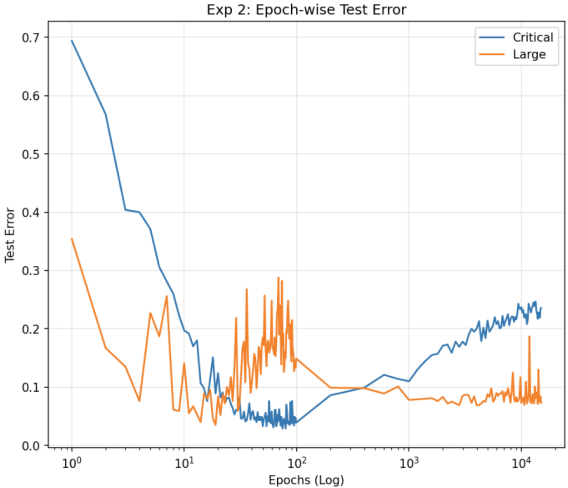

I Limiti Dimensionali del Neural Collapse

- Matematicamente, un Simplex ETF perfetto con K classi richiede una dimensione latente $d \geq K - 1$.
- Per MNIST-1D ($K = 10$), ci aspettiamo il collasso a partire da $d = 9$.
- **Verifica Empirica:** NC2 crolla verticalmente e si stabilizza a zero esattamente in corrispondenza del limite teorico.

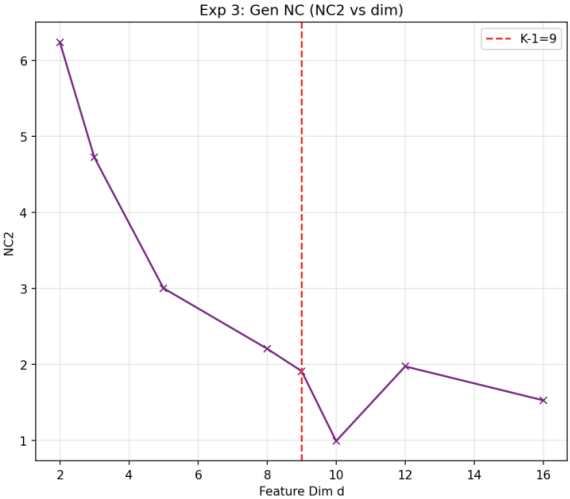

CKA: Differenze Strutturali (Small vs Large)

CKA: Misura la similarità geometrica $(0 \to 1)$.

- **L0/L1:** CKA elevato. Reti critiche e sovra-parametrizzate estraggono le stesse feature a basso livello.
- **L3 (Profondo):** CKA crolla (≈ 0.34).
- Il modello piccolo non ha i gradi di libertà per creare il Simplex ETF, generando una topologia finale diametralmente opposta.

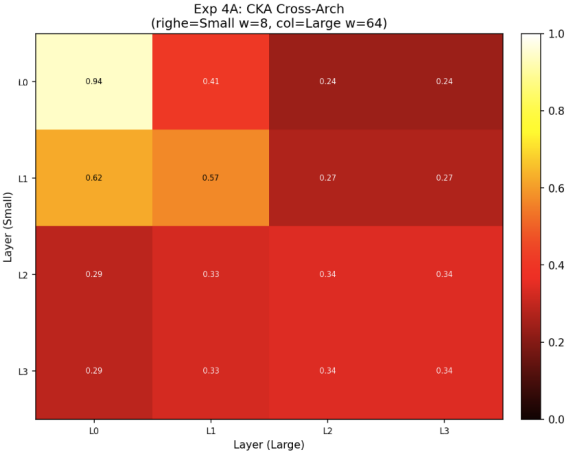

CKA: La Deriva nel Tempo (Epoch Drift)

Confronto delle attivazioni epoche successive rispetto all'epoca 1:

- **Stem (L0):** Converge subito (CKA costante vicino a 1).
- **Layer Profondi (L2, L3):** Deriva continua (drift). Lo spazio latente si riorganizza per migliaia di epoche, spinto dalla minimizzazione della varianza intra-classe.

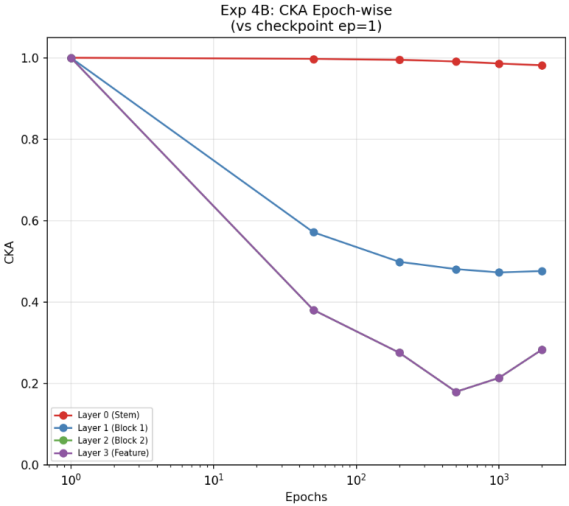

CKA: Riproducibilità e Degenerazione Geometrica

Stesso modello ($W = 32$), solo *Seed casuali iniziali diversi*:

- L0 apprende feature deterministiche ($CKA = 0.97$).
- **L3 varia molto ($CKA = 0.59$).**
- **Degenerazione Geometrica:** Esistono infinite rotazioni ortogonali per creare un Simplex perfetto. Le reti convergono a soluzioni logicamente isomorfe, ma in coordinate assolute diverse.

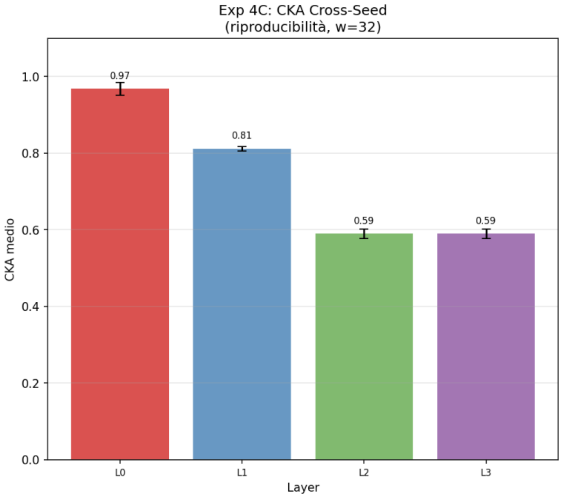

Conclusioni

1. **Il legame Empirico:** Il fenomeno del Double Descent è intimamente legato alla rottura (nel regime critico) e successiva ricostruzione (nel regime massivo) del Neural Collapse.
2. **Ottimizzazione:** SGD domina Adam, fungendo da regolarizzatore implicito che guida le reti verso un Simplex ETF perfetto.
3. **Geometria Profonda:** Il CKA ha rivelato la disomogeneità dell'apprendimento. Mentre i primi strati sono statici e deterministici, l'ultimo strato degenera geometricamente compiendo una lenta riorganizzazione per massimizzare i margini.

Grazie per l'attenzione!

Domande?